# Die Programmiersprache MYLL: C++ Resyntaxed??? und Erweitert

Eine Weiterentwicklung der C Style Syntax

# The MYLL Programming Language: C++ Resyntaxed and Extended

Eine Weiterentwicklung der C Style Syntax

in Partial Fulfillment of the Requirements for the Degree

# Master of Science Informatik

at

# Hochschule Niederrhein

by

# Jan Helge Reitz

Born 1978-10-06 in Moers, Germany

# **Abstract**

Ich schlage eine neue Syntax für C++ vor, welche den Umgang mit C++ unproblematischer und den Einstieg erleichtern soll.

Die von mir vorgeschlagene neue Syntax für C++ hat den Codenamen **Myll** (*frei von My Lang*). Der Fokus des Sprach-Designs balanciert zwischen zwei grundlegenden Zielen; zum einen soll er alteingesessene C++ Programmierer abholen und dessen Arbeit in Zukunft leichter gestalten und zum anderen soll es Neulingen den Einstieg, in eine immer komplizierter werdende Sprache, erleichtern.

Um dieses Ziel zu erreichen habe ich viele Sprachkonstrukte auf die Probe gestellt und mir überlegt wie man diese besser gestalten kann, teils von anderen Sprachen inspiriert, aber auch komplett selbst erdacht.

Des Weiteren soll Myll einfach ergänzbar sein: Beispielsweise nutzen QT, UE4 und viele andere Bibliotheken *Makros*, welche an den richtigen Stellen in den Code eingesetzt werden und teilweise durch einen zusätzlichen Präprozessor ausgeführt werden. Diese verstreuten Makros können in Myll etwa durch ein Klassen- oder Variablen-Attribut ersetzt werden.

Durch die Nutzung von Myll ließen sich auch eigene Warnings/Errors im Falle der Nutzung vom Projekt verpönten/untersagten Sprachkonstrukten einbauen.

Umgesetzt ist Myll als ein Language to Language Compiler, auch Transpiler genannt. Dieser erzeugt als Ausgabe keinen Maschinencode, sondern Quellcode einer anderen Programmiersprache, in diesem Fall C++.

Betrachtet wird die Umsetzbarkeit dieses Unterfangens; Lässt sich eine ähnlich komplexe Programmiersprache wie C++ überhaupt handhaben? Welche Aspekte von C++ sind problematisch und lösbar? Sind ähnlich positive Aspekte zu erzielen wie es Transpilation bei Webentwicklungen hervorgebracht hat? ??? erklären ???

Es soll auch gezeigt werden das durch diesen Zwischenschritt, viele positive Merkmale anderer Sprachen einfach verfügbar gemacht werden können.

??? Kürzen ???

# Inhaltsverzeichnis

Abstract	3
Inhaltsverzeichnis	4
1 Einleitung	6
1.1 Definitionen	6
1.1.1 Formatierung dieses Dokumentes	6
1.1.2 Begriffsdefinitionen	6
1.2 Idee / Motivation	
1.2.1 Alteingesessene C++ Programmierer abholen	8
1.2.2 Neulingen den Einstieg erleichtern	
1.3 Grundlagen	
1.3.1 Was macht C++ besonders?	9
1.3.2 Wieso noch eine neue Programmiersprache?	9
2 Analyse	
2.1 Vergleich von C++ mit anderen Sprachen	11
2.1.1 Vergleich mit C	11
2.1.2 Vergleich mit C# und Java	11
2.1.3 Vergleich mit D	11
2.1.4 Vergleich mit Rust	12
2.1.5 Vergleich mit Ruby	12
2.2 Problematische Aspekte von C++	13
2.2.1 Deklarationen, Definitionen und Initialisierung	
2.2.2 Fehleranfällige Variablen & Typen Deklarationen	
2.2.3 Schlechtes Standardverhalten	16
2.2.4 Inkonsistente Syntax	
2.2.5 Problematische Reihenfolge der Syntax	
2.2.6 Schwer durchschaubare automatische Verhaltensweisen	
2.2.7 Schlechte Namensgebung	
2.2.8 Verbose Schreibweise	20
2.2.9 Keyword reusage	
2.2.10 East Const und West Const	
2.2.11 WOANDERS HIN:???	
3 Konzept	22
3.1 Design der Syntax	
3.1.1 Grundsätze der Sprache Myll	22
3.1.2 Grundsätze Englisch	
3.1.3 Neue Keywords	
3.2 Behandlung der Probleme	
3.2.1 Deklarationen, Definitionen und Initialisierung	
3.2.2 Fehleranfällige Variablen & Typen Deklarationen	
3.2.3 Schlechtes Standardverhalten	26
3.2.4 Inkonsistente Syntax	
3.2.5 Problematische Reihenfolge der Syntax	
3.3 Neue Features welche keine Probleme	
3.3.1 Benamte Parameter	29

4 Implementierung	
4.1 Umsetzung	
4.2 C++ predigen, aber C# und Java trinken	
4.3 Alternative Umsetzungsmöglichkeiten	
5 Auswertung & Zusammenfassung	
6 Ausblick	34
6.1 Intelligentere Parameter Übername	34
6.2 Ranges	35
6.3 Rest	35

# 1 Einleitung

#### 1.1 Definitionen

# 1.1.1 Formatierung dieses Dokumentes

Normaler Text mit einem "Eingebetteten Zitat" und dann weiter mit etwas höchst Wichtigem.

```
"Dies ist ein Blockzitat
Von einer im Text benannten Person"
```

Exemplarisch eine Codedatei mit dem Namen myfile.cpp:

```
// Dies hier ist Code
int a;
float b;
```

Hier wird auf die Variablen a und b Bezug genommen und die Typen *int* und *float* erwähnt, stets im Singular. Wenn Code im Fließtext geschrieben wird dann sieht es so aus int a[] = {1,2,3};.

# 1.1.2 Begriffsdefinitionen

In jedem Dokument, welches über mehrere Programmiersprachen schreibt, müssen zunächst Mehrdeutigkeiten und Kollisionen ausgeräumt werden. Besonders Erwähnenswert sind die Unterschiede zur Namensgebung in C++, auf welche sich Myll ja stützt.

In dieser Arbeit werden oft die englischen Varianten von Begriffen aus der Informatik / Programmierung genutzt. ??? erläutern

#### ??? Wird am Ende Sortiert

#### GC - Garbage Collection

???

#### C++

Wenn ich über C++ schreibe, dann meine ich sehr oft beides: die *Sprache C++* an sich und die *C++ Standard Library*. Diese sind, insbesondere seit C++11, sehr eng miteinander verbunden; so wurde die Sprache erweitert um bestimmte Funktionalität in der Bibliothek zu ermöglichen. Ebenso sind Komponenten der Bibliothek Notwendig um die Sprache vollständig zu nutzen.

Beispiele: std::initializer list, std::move, std::dynamic cast

??? überabeiten

#### Keyword - Schlüsselwort

Wort mit spezieller Bedeutung innerhalb der Sprache welches nicht für eigene Namen verwendet werden kann.

#### FhO - Funktion höherer Ordnung

Beschrieben im Kontext einer Prozeduralen Programmiersprache:

Eine FhO ist eine Funktion, welche eine weitere Funktion (oder auch Lambda) und eine Kollektion als Parameter übergeben bekommt. Die übergebene Funktion wird auf jedes Element der Kollektion angewendet. Diese Kollektion kann auch durch einen Iterator repräsentiert werden.

#### **TMP - Template Metaprogramming**

Alternative Art der Programmierung bei der die Logik zur Kompliationszeit ausgewertet wird.

#### **Dynamisches Array**

Der std::vector aus der C++ Standard Library ist ein dynamisch wachsendes Array und wird in diesem Dokument *Dynamisches Array* oder *dyn\_array* genannt.

#### Map & Reduce

*Map* ist eine FhO, bei der pro Ursprungselement ein Zielelement erzeugt wird, welche wiederum in einer Kollektion gespeichert werden. In C++ ist dies durch std::transform implementiert.

Sie wird oft zusammen mit der FhO namens *Reduce* genutzt, welche aus allen Ursprungselementen ein einzelnes Zielelement erzeugt.

???MOVE ins Kapitel

In C++ ist dies als std::accumulate, neuerdings auch als std::reduce implementiert.

Ein simples Map & Reduce Beispiel in Ruby:

```
fortytwo = [4, 6, 14].map{|e| e / 2}.reduce{|accu,e| accu * e}
```

Die drei Zahlen im Array (4, 6, 14) werden zunächst in *map* jeweils durch 2 dividiert, dann in *reduce* in einen Akkumulator aufmultipliziert und ergeben die Zahl 42.

#### **Sorted Dictionary & Search Tree**

Ein sortiertes assoziatives Array welches in C++ als std::map bekannt ist.

#### **Unsorted Dictionary & Hash Table**

Ein unsortiertes assoziatives Array welches in C++ als std::unordered\_map bekannt ist.

#### **Funktion & Prozedur**

Manche Programmiersprachen unterscheiden hart zwischen diesen zwei Unterprogramm-Typen. Zum Beispiel liefern in Pascal *Prozeduren* keine Rückgabewerte. Außerdem wird in vielen Sprachen in *Funktionen* das Resultat nur aus den Eingaben erzeugt und hat keine Nebeneffekte, dieser Spezialfall wird hier "pure Funktion" genannt. In C++ werden all diese Unterprogramme Funktionen genannt, da es dort aber kein Keyword dafür gibt, konnten Benutzer der Sprache natürlich ihre eigene Namensgebung verwenden.

In diesem Dokument wird sich der Gepflogenheit von C++ bedient: Alles sind Funktionen und können, soweit nicht anders annotiert, Nebeneffekte haben und auch *void* zurückgeben.

 $\{\{\{My|I \text{ führt Keywords für Funktionen ein und bietet beide Namensgebungen um beide Lager abholen. Diese können im fast synonym genutzt werden, analog zur Einführung von$ *class*zu*struct* $in <math>C++.\}\}$ 

#### Methode

Ist eine Funktion die mit einem Objekt verknüpft ist.

#### UB - Undefined Behavoir - Undefiniertes Verhalten

Tritt auf wenn der Programmierer die Regeln der Sprache verletzt. Nach deren Auftritt ist es dem Programm erlaubt jedwedes Verhalten zu zeigen. Bei dieser Art der Fehlfunktion muss ein C++ Kompiler weder die Kompliation abbrechen, noch eine Warnung ausgeben.

#### Proto-Myll

Enthält nur Teile der Myll-Syntax, welche im aktuell betrachteten Kontext Sinn machen.

#### Konstrukte

Alles innerhalb einer Programmiersprache: Deklarationen, Definitionen, Statements, Expressions, Attribute.

# 1.2 Idee / Motivation

Die Idee zur Entwicklung dieser Sprache kam mir ursprünglich durch ein schon etwas älteres Dokument namens 'A Modest Proposal: C++ Resyntaxed' von Werther und Conway. In Ihrem Dokument bemängeln sie zurecht einige Unschönheiten in der Grammatik von C++, welche zum Teil der Kompatibilität zu C geschuldet ist. Ihre syntaktische Reimaginierung von C++ nennen sie **SPECS**.

Auch der Erfinder von C++, Bjarne Stroustrup, glaubt

"within C++ there is a much smaller and cleaner language struggling to get out"

was er in 'The Design and Evolution of C++' schrieb, welches auch SPECS zitierte.

(:Neu formulieren:)

Diese Meinung teile ich, denn wenn ich beim schreiben von C++ Code nachdenke wie ich es umsetze, dann habe ich wesentlich kompaktere Gedanken, als nachher die Umsetzung aussieht.

Zwar hat modernes C++ (11/14/17) frischen Wind in die Sprache gebracht, aber trotzdem fast keine Zöpfe abgeschnitten. Auch wurden neue Sprachkonstrukte eingeführt welche teils syntaktisch unschön und verbos sind, dem geschuldet das alter Code durch diese Ergänzungen nicht aufhören darf zu Funktionieren.

Kleine Beispiele der neuen Features.!!!

Retrospektiv betrachtet hat die in SPECS vorgeschlagene Syntax nicht mehr viel mit C++ zu tun und dessen stark von Pascal angehauchte Syntax liegt fern von meinem Ästhetikempfinden. Mein Lebensweg als Programmierer ist von C und C++ ähnlichen Sprachen geprägt weshalb die hier vorgestellte Lösung weit von der von SPECS abweicht.

# 1.2.1 Alteingesessene C++ Programmierer abholen

Alteingesessene C++ Programmierer abholen und dessen Arbeit in Zukunft leichter zu gestalten.

- Don't fix what's not broken
  - Welche Aspekte sind bewahrenswert
- Provide an easy exit path, no time invested is ever wasted
  - Generierter Code soll einmalig übernehmbar und lesbar sein
- Close to modern C++
  - Semantisch wie C++
  - Syntax entschlackt
- Make features available earlier than the C++ Standard Committee does
  - o Zuerst indem man sie emuliert (siehe Polyfills), in Zukunft indem man sie einfach durchreicht.

# 1.2.2 Neulingen den Einstieg erleichtern

Neulingen den Einstieg in eine immer komplizierter werdende Sprache zu erleichtern.

- Unify Code in one file
  - Hilft bei DRY
  - Was gehört in welche Datei?
  - · Keine .cpp, .h, .impl.h, .inl.h Dateien mehr nötig
- Fix broken defaults ???
  - o Implicit constructor, private inheritance
- Fix cumbersome constructs

- o Includes
- Fix common pitfalls
- Provide convenience known from other contemporary languages

!!!Detaillierter beschreiben was jedes Einzelne bedeutet.

Diese Ziele stehen sich natürlich auch, teils extrem, entgegen. Ich versuche einen gangbaren Mittelweg zu finden und Entscheide im Zweifel meist für die zukünftige Wartbarkeit und gegen die Vergangenheit.

# 1.3 Grundlagen

#### 1.3.1 Was macht C++ besonders?

Es gibt sehr viele neue und moderne Programmiersprachen die vielfältige Einsatzgebiete haben, einfacher und sicherer zu benutzen sind und in Teilbereichen performanter als C++ sind. Trotzdem weigert sich C++ (weiter???) an Popularität einzubüßen. ??? an relevanz zu verlieren

??? was ich sagen will ist: Ja, es ging mal begab, aber dieser fallende Trend setzt sich nicht fort

Einsatzgebiete in denen häufig C++ für die Umsetzung verwendet wird:

- Betriebssysteme
- Treiber
- Embedded Computing
- Computerspiele
- Simulationen
- Statistik

In diesen Bereichen wird C++ entweder aufgrund seiner guten Performance oder wegen der geringen Größe der Laufzeitumgebung und des Kompilats eingesetzt. C++ war früher auch als Entwicklungssprache für Desktopanwendungen verbreitet, wurde in diesen Bereichen aber in weiten Teilen von Java, C# aber auch von Webanwendungen abgelöst.

Wieso hält sich C++ in den genannten Bereichen so hartnäckig?

- Maximale Kontrolle über den Speicher
- Keine erzwungene Garbage Collection (GC)
- Keine / schlanke Laufzeitumgebung
- Native Binärdateien
- Nichts bezahlen, was nicht genutzt wird (abschaltbar: RTTI, Exceptions, Bounds/Overflow checks, etc)
- Keine erzwungene virtuelle Vererbung
- Mehrere Jahrzehnte alter C und C++ Code läuft fast immer ohne Anpassung

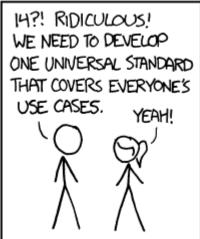
# 1.3.2 Wieso noch eine neue Programmiersprache?

Warum eine neue Programmiersprache wenn C++ doch seine Bereiche so erfolgreich bedient? Weil es sich mit vielen der anderen hier betrachteten Sprachen einfacher entwickeln lässt als mit C++.

Trotzdem wären viele Sprachkonstrukte, sobald man sie auf Sprachebene und nicht nur auf Bibliotheksebene angehen kann, eigentlich leicht übertragbar auf C++.

# HOW STANDARDS PROLIFERATE: (SEE: A/C CHARGERS, CHARACTER ENCODINGS, INSTANT MESSAGING, ETC.)

SITUATION: THERE ARE 14 COMPETING STANDARDS.



SOON:

SITUATION:
THERE ARE
15 COMPETING
STANDARDS.

https://xkcd.com/927/

# 2 Analyse

# 2.1 Vergleich von C++ mit anderen Sprachen

Als Kompliationsziel von Myll soll zwar C++ dienen, jedoch mag sich Myll zum einen Syntaktisch und zum anderen von den Features anderer Programmiersprachen inspirieren lassen. Aus diesem Grund sei hier C++ mit einigen ausgewählten Programmiersprachen verglichen.

# 2.1.1 Vergleich mit C

Der Vorgänger von C++.

- + Viel Kontrolle, man sieht genau was passiert
- + Viel simpler als C++
- + Sehr viel Freiheiten, aber auch Verantwortung bei der Speicherverwaltung
- Schlechte Encapsulation / Keine Native OOP Unterstützung
- Unübersichtlich bei großen Projekten, denn ohne Namespaces landet alles im globalen Raum
- Ursprung der meisten hier betrachteten Syntaktischen Schwächen

#### Lerneffekt für Myll:

Keine Kompromisse in Bezug auf C's Syntax

# 2.1.2 Vergleich mit C# und Java

C# und Java sind als designierte Nachfolger von C++ mit einer Transfusion dessen OOP Bluts entstanden. Sie haben sehr viel untereinander gemein und werden deshalb hier gemeinsam betrachtet.

- + Es ist leichter fehlerfreien C# und Java Code zu schreiben
- + Fehlermeldungen in Generics/Templates beschreiben viel präziser potentielle Fehlerfälle
- + Einfach auf vielen Architekturen ausführbar (oft keine Neukompilierung nötig)
- + Weniger LOC für die Lösung des gleichen Problems
- + Viele äquivalente Features viel früher verfügbar als in C++ (concepts, auto, ranges, ...)
- Erzwungene GC
- Keine multiple Vererbung
- Wenig Kontrolle über den Speicher
- Nicht abschaltbare Bounds/Overflow checks, Reflection, Exceptions
- Ein Performance Defizit welches bei Desktopanwendungen verschmerzbar ist, jedoch bei den Performancekritischen Einsatzgebieten nicht. (Siehe: Was macht C++ besonders?)

#### Lerneffekt:

Weiter Featurevorsprung zu C++ Entschlackte Syntax

# 2.1.3 Vergleich mit D

D hatte sich vorgenommen die Reihe der Sprachen BCPL -> C -> C++ -> D fortzusetzen.

Dieses hohe Ziel konnte D nicht erreichen, obwohl vieles von C++ gelernt und wohl möglich besser gemacht wurde.

- + Sehr nah an C++ angelehnt
- + Weniger LOC für die Lösung des gleichen Problems
- Erzwungene GC
- Keine multiple Vererbung
- Wenig Kontrolle über den Speicher

#### Lerneffekt für Myll:

Myll hat sich ein ähnliches Ziel wie D gesetzt; Nämlich ein besseres C++ zu sein. Myll verzichtet nicht (absichtlich) auf Kernfeatures von C++.

# 2.1.4 Vergleich mit Rust

Eine sehr neue Programmiersprache welche ihren Fokus auf die Sicherheit dessen was maschinell überprüfbar ist legt. Die statischen Überprüfungen welche der Rust Compiler vornimmt sind in der Ausprägung noch nicht verbreitet gewesen.

- + Stärkere statische Checks welche zu wesentlich sicherem Code führen sollen
- + In Zukunft ist Rust ein Contender um einige Bereiche welche C++ heute bedient
- (Anfänglich) schwerer zu schreiben durch Paradigmenwechsel des Lifetimemanagements

#### Lerneffekt für Myll:

Eine leicht verbesserte Sicherheit wird dadurch erreicht dass manches Standardverhalten angepasst wird, welches einen vor Flüchtigkeitsfehlern beschützt.

Eine Konkurrenz zu Rust in Sicherheitsfragen will Myll nicht werden.

# 2.1.5 Vergleich mit Ruby

Dieser Vergleich ist ein wenig weiter her geholt als die anderen betrachteten Sprachen. Ich wollte hier dennoch gern über den nahen Tellerrand hinausblicken um mich auch von weiter weg inspirieren zu lassen.

- + Unglaublich wenig Code ist nötig um simple Probleme zu lösen
- + Lambdas sind schon sehr lange ein gut integrierter und fast unsichtbarer Teil der Sprache
- Interpretierte Sprache (mit GC, keine Kontrolle über den Speicher, langsam)
- Keine Typsicherheit

# 2.2 Problematische Aspekte von C++

Einige der problematischen Konstrukte in C++ sind der direkten Kompatibilität mit C geschuldet, andere sind von C++ so eingeführt worden.

Als Quelle dient zu Teilen das Buch 'The C Programming Language' von Kerninghan und Ritchie.

(Mehr Referenzieren!!!)

# 2.2.1 Deklarationen, Definitionen und Initialisierung

C++ verhält sich selbst in sehr simplen Beispielen wie eine Single-Pass parsende Programmiersprache und erfordert dadurch vom Programmierer ein hohes Maß an Aufmerksamkeit bei der Reihenfolge der Programmierung oder fordert die Wiederholung von bereits Niedergeschriebenem.

# 2.2.1.1 Reihenfolge und Prototypen

Dieser Code kompiliert so nicht, er wirft den Fehler das a() nicht deklariert wurde.

```
int main() {
    a();
}
a() {...}
```

Um diesen Fehler zu beseitigen müssen wir entweder den Code so umstellen das a() vor main() definiert wird oder wir fügen eine Prototypen-Deklaration für a() vor main() ein.

Im Falle eines alternierend rekursiven Funktionsaufrufs bleibt einem nur die Möglichkeit des Prototypen.

```
void partition(...);
void qsort(...) { ... partition(...); ... }
void partition(...) { ... qsort(...); ... }
```

Computer sind schnell genug diese Probleme für einen zu lösen. Lediglich der C als auch C++ Standard stehen der Unterstützung solch einfacher Inferenz??? im Wege.

# 2.2.1.2 Aufteilung auf verschiedene Orte

Deklarationen, Definitionen und Initialisierung können entweder innerhalb einer Datei an verschiedenen Stellen und verschiedenen Schreibweisen vorkommen oder oft sogar über Dateigrenzen hinweg verteilt sein.

Dies macht den Code schwerer durchschaubar. Jegliche andere moderne Programmiersprachen erlaubt es einem (oder zwingen einen gar dazu) alles was z.B. zu einer Klasse gehört in einer einzelnen Datei abzulegen.

Dieses Beispiel soll einige Probleme aufzeigen:

Datei *myclass.h*:

```
virtual int myVirtual();
}
int MyClass::myFunc3() const {...} // Kann inlined werden, Keyword const wird wiederholt
```

#### Datei myclass.cpp:

#### Bewertung:

- Manche Keywords müssen in Deklaration und Definition geschrieben werden, andere nicht
- Der Abschnitt "MyClass:: " wird sehr oft wiederholt geschrieben
- Oft gibt es mehre unterschiedliche Möglichkeiten das gleiche zu schreiben

# 2.2.1.3 Aufteilung im Kontext lebendiger Codebases

Die Verteilung auf mehrere Dateien ist besonders problematisch wenn ein C++ Projekt *lebt*, d.h. es immer wieder einschneidende Änderungen gibt. So muss im Beispiel das eine Methode *inline* fähig gemacht werden soll (selbst wenn die Logik unverändert bleibt) ihre komplette Implementierung aus der .cpp Datei ausgeschnitten und in die .h Datei eingefügt werden. Dadurch verliert man z.B. in seiner Versionsverwaltung den Bezug und kann nicht mehr einfach die Veränderungshistorie der Methode nachschlagen.

Das gleiche Problem tritt auf wenn eine Klasse templatisiert werden soll, nur muss in diesem Fall die komplette Implementierung in die Header Datei wandern.

# 2.2.2 Fehleranfällige Variablen & Typen Deklarationen

Wie findet die Deklaration von Variablen in C & C++ statt und welche Problematischen Situationen können dabei entstehen.

# 2.2.2.1 Ambiguität einer Deklaration

Sind die folgenden Statements Deklarationen oder nicht?

```
a * b;
c d;
c e();
```

Die Antwort darauf lautet: Es kommt drauf an.

Sollte *a* ein Typ sein, wird *b* als ein Pointer auf ein *a* Deklariert, ist *a* aber eine Variable wird a.operator\*(b) aufgerufen. Der andere Fall ist zum einen *d*, welcher eine Variable vom Typ *c* deklariert und zum anderen *e* welcher grade nicht eine Variable vom Typ *d* deklariert die den Standardkonstruktor aufruft, sondern es ist eine Prototypen-Deklaration einer Funktion namens *e* welche ein *c* zurück gibt.

Diese Probleme bieten sich nicht nur dem Leser dieser Statements, sondern auch der Compiler musste aufwändiger erstellt werden um diese Konstruktionen richtig interpretieren zu können. Belege???

#### **2.2.2.2** Pointer

Naiv hätte ich bei der Variablendeklaration von

```
int * ip, jp;
```

erwartet das *ip* und *jp* Pointer auf *int* sind. Damit lag ich (so wie viele meiner Kommilitonen und Kollegen) falsch und als ich zum ersten Mal über dieses Problem stolperte, stellte sich nach etwas Recherche raus das *ip* ein Pointer und *jp* nur ein *int* Objekt waren, richtig wäre an dieser Stelle

```
int *ip, *jp;
```

gewesen.

Der Ursprung dieser Syntax ist in [K&R] so beschrieben:

```
"The declaration of the pointer ip,

int *ip;
is intended as a mnemonic; it says that the expression *ip is an int."
```

Das heißt dass man später durch Aufruf von \*ip an das bezeigte int gelangt. Kommt noch ein zweiter Variablenname hinzu, muss auch er mit der Eselsbrücke versehen werden wie man an sein int gelangt.

Obwohl ich diese Gedächtnisstütze jetzt schon lange kenne, arbeitet mein Hirn mit einem anderen mentalen Modell. In diesem Modell besteht eine Variablendeklaration aus einem Typ (der Indirektionsebenen beinhaltet) und einem oder mehrerer Namen. Nicht aus einem Basistyp (ohne Indirektionsebenen) und Namen vermischt mit Eselsbrücken wie ich an den Basistyp komme.

Als eines von vielen möglichen Beispielen von Template-Klassen verhalten sich die in C++11 eingeführten Smartpointer getreu meinem mentalen Modell, so das

```
unique_ptr<int> ip, jp;
```

jeweils ip und jp als (Unique) Pointer auf ein int definiert werden.

# 2.2.2.3 Array

Ein ähnliches Bild wie bei den Pointern findet sich bei der Syntax zur Definition von Arrays [K&R]:

```
"The declaration
int a[10];
defines an array a of size 10, that is, a block of 10 consecutive objects named a[0], a[1], ..., a[9]."
```

Auch hier kommt man im Nachhinein durch Aufruf von a[zahl] an die jeweiligen *int*, interessanterweise ist aber genau der Aufruf von a[10] ein Fehler welcher UB hervorruft. Um zwei oder mehr Arrays zu erzeugen muss man dies hier schreiben: int a[10], b[10];

Das C++11 Äquivalent dazu ist array<int,10>a, b; bei dem wieder a und b jeweils Arrays der Größe 10 vom Typ *int* sind.

# 2.2.2.4 Die Kombination von Pointern und Arrays

Sofern man Variablen immer jeweils einzeln erzeugt oder man dem sich mit K&Rs mentalem Modell anfreunden konnte, aber man dennoch nicht auf etwas Problematik verzichten will, dann kann man die beiden zuvor genannten Fälle kombinieren:

```
int *c[4];
```

Man weis hier zwar das \*c[4] ein int ist, aber der Teil mit dem int ist auch das leicht Verständlichste.

Ob dies ein Pointer auf ein Array mit 4 *int* ist oder ob es ein Array aus 4 Pointern auf *int* ist ist nicht direkt ersichtlich. Dafür muss man wissen welche Operation zuerst ausgeführt wird, die Dereferenzierung oder das Subskript. Und es stellt sich noch eine weitere Frage: Wenn es das Eine ist, wie bekommt man es dazu das Andere zu sein?

(Auflösung: Es ist ein Array mit 4 Pointern auf int. Die Umkehr wird durch Klammersetzung im Typen erreicht: int (\*c)[4];)

Alternativ dazu sind die C++11 Äquivalente zwar schreibintensiv, aber eindeutig und direkt verständlich:

```
unique_ptr<array<int,4>> uptr_to_ary;
array<unique_ptr<int>,4> ary_of_uptr;
```

### 2.2.2.5 Funktionspointer

Ein besonders schwer zu lesen und schreibender Teil der C & C++ Syntax ist die der Funktionspointer. Hier 2 Beispiele:

```
int f(int a,int b) {...} // Definition der Funktion f mit zwei int Parametern und int Rückgabe int(*fp)(int,int) = f; // Pointer auf eine Funktion fp vom gleichen Typ wie f, die auf f zeigt void(*ffp)(int(*)(int,int)); // Pointer auf eine Funktion fp die einen Parameter vom Typ von fp hat
```

Das Problematische hier sind die Funktionspointer deren Namen inmitten der Deklaration *versteckt* ist, welches sich noch undurchsichtiger bei verschachtelten Funktionspointern auswirkt, da diese Namenlos nur durch ein "(\*)" identifiziert werden.

Die zweite Zeile kann auf den ersten Blick für eine Functional Cast Expression oder eine Deklaration eines Pointers auf ein int gehalten werden; vergleiche mit der Auflösung des vorangegangenen Punktes: int(\*c) [4];

### 2.2.3 Schlechtes Standardverhalten

#### 2.2.3.1 Ein Parameter Konstruktor

Ein Konstruktor, welcher einen einzelnen Parameter übernimmt, erfüllt nicht nur die Rolle eines Konstruktors mit einem Parameter, sondern er exponiert damit auch die Funktionalität der impliziten Konvertierung des Parametertypen zum Klassentypen. Dieses Default-Verhalten bringt den nicht-Profi in die Situation, Funktionalität bereitzustellen ohne davon zu wissen.

```
class C {
     C(int) {...}
     explicit C(float) {...}
};
C c1 = C(1);
C c2 = 2;
C c3 = C(3.0f);
C c4 = 4.0f; // Compiletime Error
```

Der Entwickler wollte c1 und bekommt c2 ohne jede Warnung hinzu. Gleichfalls funktioniert c3, nur c4 wird mit einem Compiletime Fehler verhindert.

# 2.2.3.2 Private Ableitung

```
class D : C {...}; // D leitet private von C ab, was keinen Sinn ergibt...
class D { C base; ... }; // ...sollte man dies gewollt haben, kann man es auch so schreiben
class D : public C {...}; // Dies ist der Fall den man üblicherweise will
```

# 2.2.3.3 Alles kann Exceptions werfen

Funktionen sind, wieder aufgrund von Kompatibilitätsgründen, auch ohne explizite Auszeichnung so definiert das sie Exceptions werfen können. Das führt dazu das man in Exception-Armen Projekten jede Funktion mit *noexcept* auszeichnen muss. Mitglieder des C++ Standardkomitees denken darüber nach in weniger Funktionalität der Standardbibliothek Exceptions zu nutzen und auch ein neues invertiertes Keyword Namens *throws* einzuführen.

#### 2.2.3.4 Switch fällt von selbst

Als *Labels* und *goto* noch ein oft genutzter Teil von Programmiersprachen war, konnte man noch einfach verstehen was an dem folgenden Beispiel falsch läuft. Da aber heutzutage, bis auf das switch/case Statement, alle Kontrollstrukturen durch geschweifte Klammern begrenzt sind, tritt der hier gezeigte Fehler nicht selten auf.

Hier wird im Falle das a = 1 ist *do\_this* ausgeführt und nach dessen ordnungsgemäßer Beendigung auch *or do that.* 

# 2.2.4 Inkonsistente Syntax

#### 2.2.4.1 Funktions- & Methodendeklarationen

In C++ gibt es zahlreiche unterschiedliche Möglichkeiten Funktionen und Methoden zu definieren.

```
float pow(float b, int e) {...} // nicht optimal weil hardgecodeter Typ auto pow(auto b, int e) -> float {...} // ab C++11, auto vorn überflüssig, aber syntaktisch nötig auto pow(auto b, int e) {...} // ab C++14 template <typename T>
T pow(T b, int e) {...} // Analog auch auto return und trailing return type Möglich [](auto b, int e) -> auto {...} // Lambda-Syntax, kein Rückgabetyp vorweg
```

Die Spezifikation der Typen von Parameter und Rückgabe ist in jedem aufgeführten Fall unterschiedlich, besonders die Positionierung des Rückgabetypen variiert stark. Die mit C++11 eingeführte Lambda-Syntax besitzt gar keine Möglichkeit eines vorangestellten Rückgabetypen mehr.

# 2.2.4.2 Notwendigkeit des Semikolons

Manchmal braucht man ein Semikolon nach Sprachkonstrukten und ein andermal braucht man es bei sehr ähnlichen Konstrukten nicht.

```
class E {...};
do {...} while(...);
namespace A {...}
while(...) {...}
if(...) {...}
```

# 2.2.4.3 Verteilung der Attribute

In C++ sind die Attribute einer Funktion / Methode chaotisch um den Kern der Deklaration verteilt. Gegeben sei dieses Beispiel, zur besseren Lesbarkeit nach logischen Gruppen umgebrochen, formatiert und erklärt:

Man beachte das *const* dreimal vorkommt, wobei sich die ersten zwei Vorkommen (redundant) auf den Rückgabeparameter, das dritte auf die Methode bezieht. Man betrachte das *virtual*, *override* und *final* verwandte Terme sind (die innerhalb einer Definition wie hier aufgeführt nicht gemeinsam verwendet werden) aber dennoch an unterschiedlichen Positionen geschrieben werden.

Diese wahllos wirkende Verteilung der Attribute ist der Evolution von C++ geschuldet, *virtual* ist ein Keyword aus der Entstehung von C++, *override* und *final* sind relativ neu und lediglich *identifiers with special meaning*, welche nur in einem speziellen Kontext als Keyword dienen. In anderen Kontexten können sie etwa als Typ oder Variablenname verwendet werden, aus diesem Grund können sie nicht an der gleichen Position wie *virtual* geschrieben werden.

??? Standard zitieren

# 2.2.4.4 Implizite Konvertierungen

In C++ sind viele unsichere implizite Konvertierungen möglich. Dies Betrifft insbesondere numerische Datentypen.

```
void foo(int) {...}
void foo(void*) {...}
int a = 707, b = 1337;
char c = a + b;
                           // Konvertierungen zu kleineren Typen erzeugten keine Warnung
static_assert(-1<1u);</pre>
                           // Dies hier schlägt fehl, weil -1 implizit zu unsigned konvertiert wird
int * ip = 0;
int * jp = NULL;
                           // O ist implizit zu jeglichem Pointer konvertierbar…
                           // ...das ist so, weil das NULL Makro oft einfach als 0 definiert ist
// Ruft foo(int) auf
foo(NULL);
foo(nullptr);
                           // Ruft foo(void*) auf
void * vp = ip;
if( a ) {...}
if( ip ) {...}
                           // Alle Pointer sind implizit zu void Pointern konvertierbar
                           // Jegliche numerische Datentypen sind implizit zu bool konvertierbar,...
                           // ...was auch für Pointer gilt
```

Das die Addition zweier int sich sehr Wahrscheinlich nicht vollständig in einem char speichern lässt, ist kein Zustand über den sich C++ beschwert. Noch absurder wird es wenn -1 nicht mehr kleiner als 1 sein soll. Das liegt daran das für diesen Vergleich von signed und unsigned int beide in unsigned int konvertiert werden. Diese Konvertierung findet höchst performant statt, was bedeutet dass das -1 signed int einfach als unsigned int reinterpretiert wird und dann den Wert 4294967295 hat, welcher nicht kleiner als 1 ist.

Um einem Pointer mit dem besonderen leeren Wert zu initialisieren wird ihm entweder 0, NULL oder nullptr zugewiesen, wobei aber nur der letztgenannte vom Typ Pointer ist. Dies wirkt sich insbesondere negativ bei Funktionsüberladungen aus, welche im Falle der Parametrierung etwa mit NULL die Integer Überladungen bevorzugen.

# 2.2.5 Problematische Reihenfolge der Syntax

#### 2.2.5.1 Unerwartete Operator Precedence

Operatoren sind im aktuellen C++ in 17 Ebenen in der Vorrangstabelle aufgeteilt und manche dieser Ebenen sind in einer Reihenfolge, in welcher man sie nicht vermuten würde. Die Kommentare zeigen mittels Klammerung welcher Teil zuerst evaluiert wird.

# 2.2.5.2 Pre- und Suffix Operationen

Ähnlich zur Variablendeklaration von Pointern in Kombination mit Arrays bietet auch das Zusammenspiel von Pre- und Suffix Operationen oft eine Ambiguität mit sich, welche Klammersetzung erfordert.

Verwirrend ist auch die Nutzung der gleichen Symbole für unterschiedliche Arten von Operationen: &, \*,

Diese werden zum einen für Unäre Prefix- sowie Binäre Operationen verwendet, als auch in doppelter Erwähnung als Prefix, Suffix und Binäre Operation.

# 2.2.5.3 Zuweisungen und Throw Expressions

# 2.2.5.4 Textkomposition mit Streams

(MOVE)

**BSPL** 

Es ist zu erwähnen das die *stream* Schreibweise bei Textkomposition inhärent suboptimal für viele Einsatzgebiete ist; z. B. bei Übersetzungen, wenn die Reihenfolge der Argumente je nach Sprache anders ist.

Myll bietet deshalb die fmt.dev Bibliothek mit an, welche eine sehr gute Mischung aus Features, Compiletime, Binarysize und Runtimeperformance bietet.

??? änderung das es nur noch eine footnote bei den ops << >> ist

#### 2.2.6 Schwer durchschaubare automatische Verhaltensweisen

# 2.2.6.1 Special Member Functions

Es gibt sechs spezielle an eine Klasse gebundene Funktionen in C++ und diese werden unter jeweils unterschiedlichen Bedingungen automatisch generiert.

Siehe: https://en.wikipedia.org/wiki/Special member functions

Default Constructor

- Destructor
- Copy Constructor
- Copy Assignment Operator
- Move Constructor
- Move Assignment Operator

Problematisch ist dies in vielerlei Hinsicht. Zuallererst muss man sie überhaupt erkennen um sie mit der notwendigen Sorgfalt zu behandeln. Drei von ihnen sind Konstruktoren, zwei davon erwarten einen einzelnen Parameter mit vorgegebenem Typ. Diese gleichen Typen erwarten auch die speziellen Zuweisungsoperatoren.

Sobald man einen davon selbst implementiert, fallen automatisch einige der anderen weg. Dies ist schwer durchschaubar und wirft im Normalfall noch zusätzliche Probleme auf, so das die Verhaltensregeln Rule-of-Three, Rule-of-Five und Rule-of-Zero erdacht wurden. Diese geben vor, das wenn man eine der speziellen Funktionen implementiert (mit Ausnahme des Default Constructors), das man in dem Zuge auch einige der anderen Implementieren soll. Anders der Fall des Rule-of-Zero, welcher vorgibt das man komplett auf die Implementierung der speziellen Funktionen (wiederum mit Ausnahme des Default Constructors) verzichten sollte.

Diese Regeln existieren auf dem Papier, aber leider nicht in der Sprache, somit ist die Validation deren Befolgung auch komplett an den Benutzer übertragen.

#### Standard from 10.2/2

Zusammenfassung:

- Man muss sie erkennen
- Sie müssen in besonderen Konstellationen auftreten
- Der Compiler validiert nichts davon

Lösung:

# 2.2.6.2 Overloading mit Vererbung, Shadowing

https://www.geeksforgeeks.org/does-overloading-work-with-inheritance

```
class Base {
    void f(int) {...};
}
class Derived : public Base {
    // using Base::f; // diese Zeile würde das Problem beheben
    void f(double) {...};
}
int main() {
    Derived d;
    d.f(1337); // Ruft Derived::f(double) auf und nicht das logischere Base:f(int)
}
```

Lösung:

Inversion des Verhaltens, erwarte vom Benutzer das er explizit erwähnt das er Shadowing will.

# 2.2.7 Schlechte Namensgebung

```
vector
map
unsigned long long int
constexpr

Lösung:
dyn_array
search_tree oder sorted_dict // vermittelt sofort das es sortiert ist
uint64
????
```

# 2.2.8 Verbose Schreibweise

```
unique_ptr
static_cast<>
(auto)
(move)
```

# 2.2.9 Keyword reusage

#### 2.2.10 East Const und West Const

Gangkriminalität zwischen verfeindeten Clans ist hier nicht gemeint, es geht lediglich um die mögliche Positionierung des Keywords const. (Auch wenn es auch hier analoge Auseinandersetzungen wie zwischen der geschweifte Klammer in neuer Zeile mit der geschweifte Klammer auf der gleichen Zeile Fraktionen gibt)

```
const int * a;
int const * b;
int * const c;
```

Die Variablendeklaration von *a* und *b* sind identisch, das *const* bezieht sich auf das *int*. Bei der Deklaration von *c* hingegen bezieht sich das *const* auf den Pointer. Das heißt dass es an manchen Stellen möglich ist

das const links von der zu attributierenden Stelle zu schreiben (west const) und an anderen rechts (east const).

Auch wenn es wesentlich häufiger der Fall ist *a* anstelle von *b* anzutreffen, gibt es in C++ nur eine Schreibweise die immer Funktioniert, welches natürlich der unnatürlichere Fall des *east const ist.* 

# **2.2.11 WOANDERS HIN:???**

FhO

LINQ

(Schöner machen, ergänzen und strukturieren)

# 3 Konzept

# 3.1 Design der Syntax

# 3.1.1 Grundsätze der Sprache Myll

- 1. Erwarte nicht vom Benutzer sich zu wiederholen, wenn es nicht nötig ist
- 2. Außergewöhnliches Verhalten muss Explizit sein
- 3. Das was man Naiv >=75% der Zeit will, kann Implizit oder Standard sein
- 4. Breche nicht mit der grundsätzlichen Semantik von C++
- 5. Breche mit C sofern es einen Nutzen bringt
- 6. Entwickle die Syntax so weiter das es zu keiner Most Vexing Parse, o.ä. kommen kann
- 7. Sei auch dann nützlich, wenn die Entwicklung am erzeugten C++ Code weitergeht
- 8. Spare nicht mit Keywords, die Lesbarkeit dankt

# 3.1.2 Grundsätze Englisch

- 1. Don't ask the user to repeat themselves, if it's not necessary
- 2. Exceptional behavior needs to be explicit
- 3. What you naively expect to happen in >=75% cases can be implicit or default
- 4. Don't break with C++'s general semantic
- 5. Do break with C if there is a benefit
- 6. Evolve the syntax that it can't have a Most Vexing Parse or alike
- 7. Be useful even if a one time to C++ translation is all that's needed
- 8. Don't be greedy with new keywords, the readability benefits

# 3.1.2.1 Bewertung der Grundsatzeinhaltung

- 1. Dedublizierung durch Reduktion auf eine Datei
- Keine Notwendigkeit von Prototypen
- 2. Implicit Konstruktoren
  - Array Decay
  - Switch Fall
- 3. Bitweise Operationen vor Gleichheit
  - Kein Shadowing
  - Switch Break
  - **Public Ableitung**
  - Noexcept
- 4. Größte Sorgfalt wurde darauf gelegt diese Semantik beizubehalten
- 5. Jeder Bruch mit der Syntax von C ist dokumentiert und dient einem Nutzen
- 6. Die Syntaktischen Makel welche in C & C++ auftraten wurden beachtet und vermieden
- 7. ??? Sei auch dann nützlich, wenn die Entwicklung am erzeugten C++ Code weitergeht
- 8. Es wurden einige Keywords eingeführt um Ambiguitäten zu unterbinden, den Code Lesbarer zu gestalten und neue Konstrukte mit angenehmer Syntax einzuführen

# 3.1.3 Neue Keywords

Myll nutzt einige neue Keywords, denn Syntax ohne Keywords hat sehr schnell alle *schönen* Konstellationen verbraucht und Monster wie dies entstehen:

Die Liste der neuen Keywords ist:

```
ctor, dtor, func, proc, method, requires, prop, get, set, refget, field, var, loop, ???
```

Es wurden Abkürzungen mittlerer Länge gewählt welches sich an die ursprünglichen Keywords anlehnt: struct(ure), enum(eration), float(ing point number), double (precision float), int(eger). Für Funktionen ist fn zu wenig Information und kollidiert zu leicht. Für Methoden wäre meth eine ungewollte Kollision mit der Droge Methamphetamin.

# 3.2 Behandlung der Probleme

Hier werden die Probleme welche in Kapitel 2.2 aufgezeigt wurden.

# 3.2.1 Deklarationen, Definitionen und Initialisierung

# 3.2.1.1 Reihenfolge und Prototypen

In Myll gibt es keine separate Deklaration und Definition, beides erfolgt in einem Schritt. Sollte im erzeugten C++ Code dadurch ein Reihenfolge Problem entstehen, wird automatisch eine Prototyp-Deklaration vor der Nutzungsstelle erzeugt.

# 3.2.1.2 Aufteilung auf verschiedene Orte

Durch diese Zusammenführung ist auch die Aufteilung auf separate Dateien unnötig geworden. Es werden natürlich für den erzeugten C++ Code weiterhin .h und .cpp Dateien erzeugt.

Das folgende Beispiel enthält die gleiche Menge an Information wie die Dateien *myclass.h* und *myclass.cpp* aus der Analyse. Es lassen sich aus diesem Beispiel die originalen Dateien (fast identisch) wiederherstellen.

Datei myclass.proto-myll:

```
class MyClass {
    int myVar;
    int myOtherVar;
    int myVar3 = 3;
    static int myStatic = 1;
public:
    MyClass() {
        myVar = 1;
                                 // Generiert wenn möglich C++ Code wie myVar im Original
        myOtherVar = 2;
                                 // Generiert wenn möglich C++ Code wie myVar im Original
    int myFunc() {...};
                                         // Kann Code wie myFunc3 im Original generieren
    [inline] int myOtherFunc() {...}
    [inline, const] int myFunc3() {...}
                                         // Kann Code wie myOtherFunc im Original generieren
    [virtual] int myVirtual() {...}
}
```

Analyse des Urspungscodes und der bereinigten Syntax, ohne Whitespace und Kommentare:

```
Ursprung, C++: 20 Zeilen, 53 Wörter, 331 Zeichen
Bereinigung: 15 Zeilen, 39 Wörter, 213 Zeichen
```

Diese Transformation brachte in diesem sehr simplen, von Implementieriung befreiten, Beispiel eine reduktion der Zeilen um 25%, der Wörter um 26% und der Zeichen um 35%. Es geht in diesem betrachteten Punkt des Konzepts auch explizit nicht um die Implementierung. Größere, realistischere Beispiele werden späteren Verlauf der Thesis Betrachtet und Ausgewertet.

# 3.2.1.3 Aufteilung im Kontext lebendiger Codebases

2.2.1.3 Erklärt lebendige Codebases???

Lebendiger Code profitiert von der irrelevant gewordenen Reihenfolge von Deklarationen und der Vereinigung auf eine Datei. Ein inline hinzu, ein inline entfernt, erzeugt eine geänderte Zeile im *diff* der Versionen.

# 3.2.2 Fehleranfällige Variablen & Typen Deklarationen

#### 3.2.2.1 Ambiguität einer Deklaration

Um der Ambiguität ob etwas Beispielsweise eine Variable, eine Multiplikation oder einen Funktions-Prototyp ist entgegen zu wirken führt Myll Keywords zur einfachen Identifikation deren ein.

```
var a * b;  // Variablen Deklaration
const a * b;  // Konstanten Deklaration
a * b;  // Multiplikation
var c d;  // Variablen Deklaration
var c e();  // Variablen Deklaration mit Aufruf des Standard Konstruktors
func e() -> c;  // Funktionsdeklaration (unnötig in Myll, mehr dazu in dediziertem Kapitel)
```

Das Keyword var für Variablen, const für Konstanten, func für Funktionen.

Inspiriert war dies von einigen anderen Programmiersprachen, aber die Entscheidung zu genau diesen Keywords kam durch das Projekt Bitwise von Per Vognsen welcher in seiner Programmiersprache **Ion** die gleichen Keywords verwendet.

# 3.2.2.2 Pointer und Array

In Myll ändert sich die Pointer und Array Syntax so das der Stern und auch das Kaufmanns-Und sowie die eckigen Klammern zum Typ gehören und der Typ für alle Variablennamen gleich ist:

```
var int* a, b; // Variablen a und b sind beide Pointer auf int var int[10] c, d; // Variablen c und d sind beides int Arrays mit 10 Elementen
```

Verloren geht dadurch die Möglichkeit total unterschiedliche Initialisierungen wie diese hier in einer Zeile schreiben:

```
int i = 1, *p = NULL, f(), (*pf)(double), a[10];
```

Diese Änderungen beseitigt nicht nur die potentiell Fehleranfällige Syntax von K&R C, sondern harmonisiert außerdem mit der Template Schreibweise in C++ und der allgemeinen Schreibweise in anderen Sprachen wie C#, Java, D.

Dies ist ein Trade-off welcher die häufiger genutzte Art der Deklaration vereinfacht und die seltener genutzte erschwert.

# 3.2.2.3 Pointer auf Arrays

Des weiteren wird eine neue Schreibweise für Pointer auf Arrays eingeführt:

```
int[*] a;
int[]* a; // besser???
```

Damit lassen sich möglicherweise schon in Myll Fehler diagnostizieren wenn ein Pointer auf ein Skalar so verwendet wird wie ein Pointer auf ein Array z.B.:

```
int skalar;
int[10] ary;
int* ptr_to_skalar = &skalar;
int[*] ptr_to_ary = &ary; // Expliziter Decay des Arrays zu einem Array-Pointer
int[]* ptr_to_ary = &ary; // Expliziter Decay des Arrays zu einem Array-Pointer, besser???
ptr_auf_skalar++; // Compiletime Error: Pointer auf Skalare verbieten Arithmetik
ptr_auf_ary++; // Funktioniert wie erwartet
```

Auch wird der implizite Decay von Arrays zu Pointern verhindert, will man, dass ein Array zum Pointer wird, nutzt man die identische Syntax um ein Pointer auf ein Skalar zu bekommen.

#### 3.2.2.4 Die Kombination von Pointern und Arrays

Die Kombination aus Pointern und Arrays ist durch die bereits genannten Änderungen schon abgedeckt und die Unklarheit der Reihenfolge, welche in C vorhanden war, ist nicht mehr vorhanden. Es gibt:

```
int[4]* ptr_to_ary_of_4; // Ein Pointer auf ein Array aus 4 int
int*[4] ary_of_4_ptrs; // Ein Array aus 4 Pointern auf int
```

Dadurch besteht keine Notwendigkeit Klammern zusetzten und auch keine ausschweifende Schreiberei??? wie bei der Template Syntax.

# 3.2.2.5 Funktionspointer

In Myll erkennt am linken Rand der Deklaration sehr schnell ob etwas eine Funktion, ein Funktionspointer oder etwas anderes ist, die Namen sind außerdem leicht auffindbar an der rechten Seite der Deklaration

Hier sind verschachtelte Funktionspointer nicht schwerer lesbar als Funktionspointer im Allgemeinen.

Das identische Beispiel in Myll:

```
func f(int,int)->int {...}
var func(int,int)->int fp = f;
var func(func(int,int)->int)->void ffp;
```

#### 3.2.3 Schlechtes Standardverhalten

#### 3.2.3.1 Ein Parameter Konstruktor

Die Lösung zum Konstruktor, welcher einen einzelnen Parameter übernimmt, ist die Umkehrung der Bereitstellung der impliziten Konvertierung. Sollte diese Konvertierung gewünscht sein, muss sie explizit erwähnt werden.

Auch Jonathan Müller, C++ Library Developer und Konferenzsprecher betrachtete dieses Problem in einem Blogpost und Urteilte:

"As with most defaults, this default is wrong. Constructors should be explicit by default and have an implicit keyword for the opposite."

Quelle: <a href="https://foonathan.net/blog/2017/10/11/explicit-assignment.html">https://foonathan.net/blog/2017/10/11/explicit-assignment.html</a>

Dieses Beispiel in Proto-Myll weist die gleiche Bereitstellung wie im C++ Beispiel auf:

```
class C {
   implicit C(int) {...}
   C(float) {...}
};
C c1 = C(1);
C c2 = 2;  // ok, da explizit erwähnt wurde das von int implizite Konvertierungen erlauben soll
C c3 = C(3.0f);
```

```
C c4 = 4.0f; // Error
```

Der Entwickler bekommt ein Funktionierendes *c1* und wie angefordert auch *c2*. Gleichfalls funktioniert *c3*, jedoch wird *c4* mit einem Compiletime Fehler verhindert.

# 3.2.3.2 Private Ableitung

```
class D : C {...}; // Dies ist der Fall den man üblicherweise will class D : private C {...}; // Wenn man will kann D private von C ableiten
```

# 3.2.3.3 Alles kann Exceptions werfen

Das für zukünftige C++ Standards angedachte Keyword *throws* ist in Myll nötig um in einer Funktion Exceptions nutzen zu können, dieses Keyword kann auch einmalig einer gesamtem Klasse zugewiesen werden.

#### 3.2.3.4 Switch fällt von selbst

Umkehr der Verhaltensweise, fall wenn Fallthrough erwünscht, break ist der default.

# 3.2.4 Inkonsistente Syntax

#### 3.2.4.1 Funktions- & Methodendeklarationen

So sehen die identischen Deklarationen in Myll aus.

```
func pow(float b, int e) -> float {...} // nicht optimal weil hardgecodeter Typ func pow(auto b, int e) -> auto {...} // Rückgabetyp func pow(auto b, int e) {...} // ab C++14 func pow<T>(T b, int e) -> T {...} // Analog auch auto return und trailing return type Möglich func(auto b, int e) -> auto {...} // Lambda-Syntax, fast identisch zur Funktionssyntax proc do_something() {...} // Momentan Synonym zu func method draw() {...} // Innerhalb von Klassen Synonym zu func
```

Funktionen und Methoden aller Art werden mit dem neuen Keyword *func* eingeleitet, die Rückgabetypen werden nur Folgend angegeben. In der Evolution von C++ wurde der folgende Rückgabetyp mit C++11 eingeführt und gewann seit dem immer mehr an Bedeutung und Funktionalität. Die Templatesyntax wurde für simple Fälle wie diesen hier entschlackt, mehr dazu in separatem Kapitel. Lambdas sind nun leichter Identifizierbar und bis auf ihre Namenlosigkeit identisch in der Schreibweise zu Funktionen.

Die Nutzung der Keywords *proc* und *method* ist auch möglich, *proc* ist momentan komplett Synonym zu *func*, *method* nur im Klassenkontext nutzbar.

Analog zu *const* Methoden, welche eine Veränderung des assoziierten Objektes verbieten, gibt es die Möglichkeit jede Funktion als *pure* zu markieren, welche die Veränderung von jeglichem globalen Zustand verbietet.

# 3.2.4.2 Notwendigkeit des Semikolons

Ohne die Notwendigkeit, wie in C, für alles via *typedef* einen nutzbaren Alias zu erzeugen, fällt auch die Notwendigkeit des Semikolons nach Klassen, Strukturen, Unions und Enumerationen weg. Verloren ist die Möglichkeit der direkten Erzeugung von Variablen des neuen Typs.

```
class E {...}
do {...} while(...)
```

# 3.2.4.3 Verteilung der Attribute

Das gleiche Beispiel auch hier nach logischen Gruppen Formatiert:

```
[noreturn, pure, virtual, override, final, noexcept] // Alles was sich auf die Methode bezieht func foo() -> const float // Rückgabetyp mit west-const {...}
```

Myll gruppiert Attribute in Eckigen Klammern vor dem jeweiligen Konstrukt, dadurch sind zukünftige Erweiterungen einfach möglich, ohne das es Kollisionen mit bestehendem Code & Syntax gibt. West const ist hier die einzig Korrekte Schreibweise um etwas const zu machen.

# 3.2.5 Problematische Reihenfolge der Syntax

#### 3.2.5.1 Unerwartete Operator Precedence

Myll ordnet die booleschen Operatoren in die Ebenen der Punkt- und Strichrechnung ein: Operator & in die Ebene der Punktrechnung, | und ^ in die Ebene der Strichrechnung.

Die Idee hierzu kam durch das Projekt Bitwise von Per Vognsen welcher in seiner Programmiersprache **Ion** die gleiche Änderung der Operator Precedence umgesetzt hat.

Der letzte aufgeführte Problemfall wurde nicht Behandelt damit dies hier noch so funktioniert:

```
if( a << 1 == 23 ) // if( (a << 1) == 23 )
```

Siehe auch 4.1.4.3. what??? leider Pointer auf umbenanntes Kapitel

# 3.2.5.2 Pre- und Suffix Operationen

Pech:

```
(*a)->draw(); // Auch bei mehrfach Dereferenzierung muss geklammert werden
```

# 3.2.5.3 Zuweisungen und Throw Expressions

Zuweisungen und throw sind keine Expressions mehr. Dadurch sind die genannten Beispiele nicht mehr valider Code und müssen in einfacher durchschaubaren Code umgeschrieben werden. In den seltenen Fällen wo eine Zuweisung eine Expression war muss sie nun einzeln als Statement geschrieben werden. C# und ??? löst es genau so.

# 3.3 Neue Features welche keine Problemfälle waren

#### 3.3.1 Benamte Parameter

```
func spawn_entity(bool is_visible) {...}
func spawn_entity(bool put_a_hat_on) {...}
spawn_entity(is_visible: true);
```

Diese beiden Funktionen würden in C++ durch ihre identische Signatur nicht gemeinsam existieren können. In Myll ist ein Aufruf mit is\_visible: true jedoch eindeutig der ersten Variante zuzuordnen. Ein Aufruf dieser mit benamten(benannten) Parametern überladenen Funktion ohne die Nennung der Argumentnamen ist allerdings nicht mehr möglich, außer der ein Attribut markiert die primär/namenlos zu verwendende Funktion oder ein Invertiertes markiert die namenlos Untauglichen.

```
[primary/nameless] func spawn_entity(bool initially_visible) {...}
// ODER
[explicit/onlynamed] func spawn_entity(bool put_a_hat_on) {...}
spawn_entity(true); // ruft die primäre Funktion auf
spawn_entity(is_visible: true); // trotzdem schöner zu lesen, weil man sieht was das true bedeutet
```

Benannt == Benamt?

BSPL von R6

bool isVisible = true;

spawn\_entity(isVisible);

# 4 Implementierung

# 4.1 Umsetzung

Meine Arbeit mit TypeScript (welches das Arbeiten mit JavaScript erträglich macht???) und ähnlichen Projekten, welche eine Source Übersetzung (Transpilation) durchführen, brachte mich dazu dieses Projekt mit dem gleichen Verfahren zu beginnen.

Durch Transpilation entgeht man vielen problematischen und arbeitsintensiven Aspekten wie:

- Erzeugung von Assembly / Maschinencode
- Optimierung von Assembly / Maschinencode
- Erzeugung eines ABI (Application Binary Interface, Binäre Repräsentation ??? move to Begriffsbla)
- Linking von Object Files
- Bereitstellung eines Debuggers

Es bietet einem die Möglichkeit eine Sprache zu bedienen, ohne sie schreiben zu müssen, sowie die gesamte Infrastruktur der Zielsprache nutzen zu können.

Auch andere aktuelle Entwicklungen nutzen Transpilation um schneller einsatzbereit zu werden wie zum Beispiel Jonathan Blow's JAI (zu C++ Code) und Per Vognsen's ION (zu C Code). C++ selbst war in seinen Anfängen (C with Classes) als Transpiler zu C-Code umgesetzt.

Myll soll direkt mit C++ Code zusammenspielen, also einer Mixtur aus .cpp/.h und .myll Dateien, es soll die C++ Standardbibliothek und C als auch C++ Libraries nutzen können.

Die Umsetzung erfolgt in C# und nutzt Antlr4 als Lexer und Parser Generator.

# 4.2 C++ predigen, aber C# und Java trinken

Man sollte immer das beste Werkzeug für seine Arbeit nutzen. Aufgrund der Komplexität eine Sprache wie C++ zu Lexen und zu Parsen, bediene ich mich eines weitverbreiteten Parser-Generators und einer einfacher zu nutzenden Sprache. Die *Performance* welche bei dieser Arbeit im Vordergrund steht, ist die Umsetzung von möglichst viel Funktionalität im gegebenen Zeitfenster, dies lässt sich einfacher mit C# realisieren.

# 4.3 Alternative Umsetzungsmöglichkeiten

Im Kontext der Erstellung dieser Masterarbeit habe ich auch Alternativen zur Umsetzung betrachtet.

- Selbstgeschriebener Lexer/Parser
  - Nach einigen kleinen Prototypen war klar das eine Programmiersprache, welche annähernd die Komplexität von C++ aufweist, sich nicht in absehbarer Zeit manuell Lexen & Parsen lässt
  - o Dieses Unterfangen wäre sicher Interessant gewesen, ist hier aber nicht der gewünschte Fokus
- C++ mit Boost Spirit X3
  - Sehr schwierig eine komplexe und rekursive Grammatik zu definieren
  - Lange Kompilationszeiten
  - Spirit X3 hat angeblich eine gute Runtime Performance
- C++ mit PEGTL
  - Sehr ähnliche Probleme wie mit Spirit X3

- C++ mit ANTLR
  - o Grammatik relativ einfach zu definieren, nah an der Backus-Naur-Form
  - Unterstützung von ANTLR in C++ ist nicht so ausgereift wie die von C#
  - o Siehe die aufgeführten Nachteile von C++ in diesem Dokument
  - Implementations-Geschwindigkeit wichtiger als Runtime-Performance
- C# mit ANTLR
  - o Grammatik relativ einfach zu definieren, nah an der Backus-Naur-Form
  - ANTLR hat die beste Interoperabilität mit C# von den unterstützten Sprachen welche ich beherrsche
  - Die Arbeit mit C# erlaubt einfache Nutzung einer Graphischen Oberfläche und hat auch sonst eine schnelle Implementationsgeschwindigkeit

#### 4.4 Details

# 4.4.1 Lexer / lexikalischer Scanner / Tokenizer

Was macht ein Lexer im allgemeinen und hier im speziellen.

Nach diesem Schritt ist bekannt ob der eingegebene Text Anomalien aufweist.

```
if if int ())); // Keine Anomalie
€" // Anomalie: € ist kein Keyword, Operator oder Identifier; »"« wird nicht geschlossen
```

Auflistung des Lexers im Anhang.???

# 4.4.2 Parser / syntaktische Analyse / Zerteiler

Was macht ein Parser im allgemeinen und hier im speziellen. Einlesen der Tokens des Lexers, Ausgabe eines AST (Abstract Syntax Tree)

ANTLR4 Adaptives LL(\*), unterstützt keine indirekte/versteckte Left-Recursion.

Kontextfreie Grammatik kann in Erweiterter Backus-Naur-Form formuliert werden.

Nach diesem Schritt ist bekannt ob der eingegebene Text Grammatisch valides Myll ist.

```
BSPL???
```

PS: C ist nicht LL(1) Parsebar.

Auflistung des Parsers im Anhang.???

# 4.4.3 Traversal / Durchlauf

Bei der Frage wie der AST durchlaufen werden soll bot ANTLR zwei Möglichkeiten: Visitor (Besucher) und Listener (Lauscher). Die Entscheidung fiel auf den Visitor, da dort der Durchlauf des Syntax Baums selbst gesteuert werden kann; man kann Visit() auf die Kinder in einer selbst gewählten Reihenfolge aufrufen oder sogar manche Teile gar nicht besuchen. Alternativ dazu durchläuft der Listener alle Knoten von selbst in vorgegebener Reihenfolge und gibt einem lediglich die Möglichkeit zuzuhören.

# 4.4.4 Semantische Analyse / Resolve Symbols

Die Semantischen Analyse ist in Myll in drei Phasen unterteilt, die erste dieser Phasen findet schon beim Traversal des AST statt. Mehr???

- 1. Globale Typendeklarationen und Identifier erfassen
- 2. Globale Typen werden vervollständigt
- 3. Funktionskörper werden Analysiert

#### Phase 1:

- Alle globalen Deklarationen werden hierarchisch durchlaufen
- Die globale Variable namens *g\_i* wird mit dem eingebauten Typen *int* erfasst, diese Deklaration ist damit schon vollständig aufgelöst und wird als fertig markiert
- *myfunc* wird global als Funktion erfasst mit *BC::Sub* als Rückgabetyp, da dieser bisher unbekannt ist, wird er aktuell nur textuell erfasst
- Implementierung von *myfunc* wird vorerst ignoriert
- BC wird global als Klasse erfasst, die Basisklasse SomeBase ist noch unbekannt und wird deswegen auch nur textuell erfasst
- Sub wird unter BC als Klasse erfasst, ist vollständig aufgelöst und wird als fertig markiert
- SomeBase wird global als Klasse erfasst
- Die Funktion c wird unter SomeBase mit Parametertyp BC::Sub textuell erfasst, T bleibt offen
- Implementierung von *SomeBase::c* wird vorerst ignoriert

#### Phase 2:

- Alle nicht fertigen globalen Deklarationen werden erneut hierarchisch durchlaufen
- Der Rückgabetyp von *myfunc* wird jetzt durch einen Verweis auf die in Phase 1 erfasste *BC::Sub* Klasse ersetzt und da ihre Signatur vollständig aufgelöst ist wird sie als fertig markiert
- Die Basisklasse von *BC* wird durch einen Verweis auf die Klasse *SomeBase* ersetzt, sie wird als fertig markiert, da hier nichts direkt auf die (bisher nicht fertige) Basisklasse *SomeBase* verweist
- Die Parametertyp BC::Sub von SomeBase::c wird aufgelöst, T bleibt offen, wird als fertig markiert
- Rückkehr zur Klasse SomeBase, diese wird als fertig markiert da alle Kinder fertig sind
- Phase 2 wird ein erneut durchlaufen sollte etwas nicht als fertig markiert sein
- Sollte die Anzahl der noch nicht fertigen Deklarationen nicht zwischen den erneuten Aufrufen schrumpfen, liegt ein fehlerhaftes Programm vor

#### Phase 3:

- Alle nicht-Template Funktionskörper werden aufgelöst
- Lokaler Scope von *myfunc* wird erzeugt
- Variable a vom Typ BC wird in lokalem Scope erzeugt
- Variable b vom Typ BC::Sub wird in lokalem Scope erzeugt
- Variable a ruft die Methode c auf, in dieser wird der Templateparameter T mit dem Typen int der globalen Variable g\_i instanziiert und der Typ der Variable b ist kompatibel mit dem ersten Parameter
- Variable *b* wird zurückgegeben, dessen Typ ist kompatibel mit dem Rückgabetyp der Funktion
- Der lokale Scope wird geschlossen
- Templatefunktionen wie SomeBase::c werden wie in C++ nur im Falle der Nutzung aufgelöst

# 4.4.5 Generator

# 5 Auswertung & Zusammenfassung

Known issues

(Partial) Template Specialization might not work, thus TMP might not work as well Keine Lambdas ATM

Es wird Code geben der von Myll nach C++ kompiliert, dann aber beim kompilieren des C++ Codes scheitert. Aufgrund von unvorhergesehener Namenskollision oder ähnlichem. Wenn man Myll in dieser Form scheitern lassen will, dann schafft man dies auch.

Letter to:

Bjarne Stroustrup,

Tell what I do and why I ask.

I know that you do not like C# because of its proprietary nature. Thus I am only interested in your opinion on just C#'s Syntax. Especially in the light of your sentence: Cleaner Language...

I personally think that C#'s syntax for defining template classes and functions is almost always as expressive as C++'s and way easier to use. Can you relate to my gut feeling?

A. Heijlsberg,

Tell what I do and why I ask.

Do I even have Questions?

A. Alexandrescu,

I recently read an Answer on Quora concerning the DLanguage

Herb Sutter

Parameter passing, sink, passing shared, unique and raw pointers

Per Vognsen,

Jonathan Blow:

NO NAGGING stuff...

You don't like the name 'Vector' for auto growing arrays, what would be your choice if you would not want to use purely 'Array'. C# calls these 'List' and Java 'ArrayList', do you think these names are good or do you have a better idea how to call them?

Read the surroundings of the quotes.

====<u>#IN</u> ====

Genereller Scope von Myll:

Einführung geplanter C++17/20 features ahead of time.

Einführung nicht von ISOCPP geplanter Features.

Änderung alter C Syntax, Modernisierung auf aktuelles C++ Verhalten. (Typen, Deklarationen)

Einführung von Funktionalität welche nur im Transpiler existiert, für warnings oder errors verwendet wird, im Endeffekt aber keinen C++ Code erzeugt.

Vielfache Nutzung von static für unterschiedlichste Zwecke

Beschränkung der Nutzung und ersetzen durch Alternativen, Bestenfalls als Attribut, kollidiert nicht mit der Sprache.

Different operator precedence table

Boolsche Operatoren sind schlecht einsortiert: a&1==0 ist a&(1==0) sollte (a&1)==0 sein.

Idee von /PV.

Neue Operatoren, von C# und selbst Ausgedachte.

All variables initialized by default, uninitialized must be specified.

Idee von /JB

Default relational ops and compound assignment

Overrideable

Header and Implementation in a single file

Assignment is a Statement where left hand side Type communicates with the right hand side

Wirkt effektiv gegen if(a=1), macht anderen code auch wesentlich schwerer obfuskierbar.

Enums can be linear or quadratic auto-indexed (flags enum)

Enums have reflection back to their string representation, oder andersherum

Leichter zu debuggen oder configs einzulesen.

Easier safe cast Expressions

Reuse the easy cast syntax from C, but this is only static cast, others equally simple

Easier use of Smartpointers

int @! a; für unique\_ptr<int> a;

Easier Template syntax

C# zeigt das es auch anders geht.

Concepts Lite Lite

Make Concepts available for all the easy cases

Spaceship Operator

**UFCS** 

Nur in einer Richtung: aus foo(a) wird das hier nutzbar a.foo()

Accessors

Getter/Setter incl. dem syntaktischen zucker welcher sie ohne () aufrufbar macht.

Implicit ret var

Functions/Procedures liefern automatisch eine Variable die ret heißt und dem Rückgabetyp entspricht.

Enum methods

# 6 Ausblick

Everything is constexpr, when it can be, you dont need to write it.

# 6.1 Intelligentere Parameter Übername

Der Programmierer muss im allgemeinen mehr Gehirnschmalz in die Gestaltung der Übernahmeparameter stecken als man Naïv annimmt.

IDEA: Jeder Typ spezifiziert zu Compiletime welche Kosten ein Copy, ein Move oder ein Referenzieren hat. Auch für Literals des Typen

Als Beispiel dient eine Funktion welche nur wenige Parameter lesen will:

```
func( int a,
    vector<int> b,
    shared_ptr<image> c,
    unique_ptr<database> d
) -> void { ... }
```

An welchen Stellen treten hier Probleme auf und welche Möglichkeiten bieten sich diese zu unterbinden?

- a. Dieser Parameter ist unproblematisch. Hier ließe sich lediglich noch ein *const* hinzufügen, was an der Korrektheit nach Außen nichts ändert, es wirkt sich lediglich als nur-lesen Einschränkung nach innen aus.
- b. Dieser Parameter hat in dieser Form eine potentielles performance Problem, da der Vektor mit seinem kompletten Inhalt kopiert wird. Mir fällt nur ein guter Grund ein dies so zu schreiben und zwar wenn man den Vektor innerhalb der Funktion ändern will, sich diese Änderung aber nicht nach aussen hin auswirken soll.
- c. Höchstwarscheinlich passiert hier das richtige, es ist im Falle des nur-lesens lediglich ein überflüssiges inkrementieren und dekrementieren des usage-counters möglich.
- d. Dies ist sehr warscheinlich ein Fehler, es sei denn man wollte wirklich das die Funktion die Datenbank konsumiert, sprich das übergebene Argument invalidiert.

Bauen wir die Parameter so um das sie warscheinlich das richtige tun.

```
func( const int ODER int ODER int& ODER int* a, const vector<int>& ODER vector<int>& ODER vector<int>* b, const shared_ptr<image> ODER const shared_ptr<image>* oDER const shared_ptr<image>* shared_ptr<image> ODER shared_ptr<image>* c, unique_ptr<database>& ODER unique_ptr<database>* oDER database* d
```

Dieses Feature lässt sich möglicherweise mit TMP lösen, wird dann aber warscheinlich eine verbose Syntax haben.

Nein, denn es ließe sich mit viel SFINAE Magic maximal die Signatur der Funktion ändern, die Position des Aufrufs bleibt unangetastet... außer es soll zusätzlich auch um jedes Argument aller Call Sites gewrapt werden, weil wenn z.B. in der decl aus T -> T\* wird muss an der call site aus arg -> &arg werden.

```
template <typename T>
void foo(typename look_t<T>:::type t) {...}
...
```

foo(look(argument));

# 6.2 Ranges

Läuft das so? int sum = container | filter | sort | reduce;

#### 6.3 Rest

#### ==== #MAYBE ====

- 'maybe\_const', is an Aspect of a Function which will make it implement a const and a non-const version of itself. It is a
- Named function arguments, makes refactoring easier and calls like this easier to read: DoSomething(false) -> DoSomething(checkBefore:false).
  - For bools even this syntactic sugar might be possible: DoSomething(!checkBefore), DoSomething(NOTcheckBefore), DoSomething(checkBefore), DoSomething(DOcheckBefore)
- Glue Classes (with UFCS?)
  - Classes that tie two or more classes together and only exist when both(all) classes are loaded
- Multithreaded compiler
- Be configurable for the user e.g. "@!" can be std::unique\_ptr or a custom pointer class
- Enable aspect oriented programming through Attributes
- Warnings for many holes in Structs due to alignment/bad ordering
- Reimagined Parameter definitions (lend, sink)
  - O Copy:
  - O Look:
  - o Edi
- UTF8 in strings, 32bit Codepoint for single chars

==== #OUT ====

Use ifs everywhere as alternative to #ifdefs
Dynamic size for integer types: i23 for a 23 bit integer

Do not piggyback on C++ anymore